Matheus Hoffmann

Florianópolis, Santa Catarina, Brasil

email mhoffmannfs@gmail.com · LinkedIn mhoffmannbr · GitHub h0ffmann · web marola.dev

Perfil

Engenheiro de software e de machine learning. Desde 2017 construo sistemas de previsão que rodam em produção, junto com as plataformas de dados e de MLOps que os sustentam: previsão de perdas numa plataforma antifraude de e-commerce, de churn numa empresa de pagamentos e de audiência numa emissora de TV. Em 2026 levei esse trabalho para o mar: o porte bit a bit do modelo de ondas WAVEWATCH III para GPU, uma plataforma aberta que transforma dados públicos de mar, tempo e balneabilidade num sinal diário para três cidades do litoral brasileiro, e a proposta de um benchmark nacional que compara previsões de ondas com medições de instrumentos. Antes da indústria, passei dois anos no Laboratório de Instrumentação Oceanográfica da COPPE/UFRJ. Para um grupo de pesquisa em oceanografia, contribuo com modelagem numérica de ondas em GPU, pipelines operacionais de previsão com verificação embutida e infraestrutura que reúne e padroniza observações de várias fontes. Trabalho com ciência aberta: cada trabalho abaixo tem DOI, repositório público e ambiente de compilação fixado e reprodutível.

Pesquisa

ww3-gpu · Hoffmann, M. (2026). *WW3 GPU Lab: agentic coding and agentic research on a bit-for-bit GPU port of WAVEWATCH III.* Software, v0.1.3. DOI 10.5281/zenodo.23221351 GitHub h0ffmann/ww3-gpu

- 520 commits no `main` até `febad48` (16/10/2026). Projeto final de graduação na Escola Politécnica da UFRJ, com coorientação no LabECO/UFSC: porte do WW3 para C++/Kokkos que reproduz o Fortran bit a bit e é validado só pelos regtests do próprio WW3. O termo de interação não linear DIA (W3SNL1), 48,4 % do tempo no perfil medido, dá os mesmos bytes que o Fortran nas 100 entradas da matriz de regtests e nas 25 com OpenMP (commits `e305841`, `7fd6bb2` e `f32640c`).
- Estado em `febad48`: 269 das 1 023 rotinas do WW3 traduzidas (99,3 % do tempo de execução), 10 chamadas pelo WW3 (87,4 %) e 2 aprovadas nos regtests (48,4 %). O núcleo DIA isolado leva 25,88 ms em Serial, 5,95 ms em OpenMP e 0,75 ms em CUDA numa RTX 4090; dentro do WW3 ainda não há ganho de tempo, e o modelo ainda não rodou em GPU.

marola · Hoffmann, M., Valério, B., Soares da Silva Junior, R. K., Oliveira, E., Almeida, L. R. e Ribeiro, P. (2026). *marola: an open, non-profit platform for sea conditions and bathing-water quality at Brazilian beaches, built on public data.* Software, v0.2.2. DOI 10.5281/zenodo.23224155 GitHub marola-dev/marola

- Classifica as praias de Florianópolis, Rio de Janeiro e Salvador para hoje e amanhã, a partir de previsões de mar, vento, ondas e maré e dos boletins oficiais de balneabilidade de três órgãos estaduais; regras simples, e não um modelo, decidem o que envolve a segurança de quem nada. Seis autores em três países; 545 commits no repositório principal até `09208c7` (16/10/2026).
- Repositórios principais (commits em 14/10/2026): **marola-app**, o produto em Scala 3 e Kyo (pipeline, servidor MCP, benchmark; 171); **marola-ml**, compilação de prompts com DSPy, fine-tuning do modelo marola-sea e portão de benchmark (79); **marola-site**, o mapa em marola.dev (106); **marola-corpus**, conhecimento oceânico com fontes (21); **marola-devkit**, hooks, plugin do Claude Code e workflows (167); **marola-research**, onde está o marola-bench (16).

Experiência

Fundador, marola.dev

Setembro de 2026 – atual · Florianópolis, Brasil

- Instituto oceanográfico sem fins lucrativos; mantenho a plataforma marola, descrita em Pesquisa

Engenheiro Sênior de Machine Learning Operations (MLOps), TXP / ITV

Julho de 2025 – agosto de 2026 · Londres, Reino Unido (remoto)

- Reestruturei um pipeline de previsão de audiência de um só canal numa plataforma de ML multicanal, e estendi as previsões para ITV2, ITV3 e ITV Quiz
- Fui responsável pelo pipeline de ponta a ponta, da ingestão à previsão publicada: AWS Glue, Amazon SageMaker e MLflow, orquestrados no Apache Airflow (MWAA), servidos pelo Amazon DynamoDB

Engenheiro Sênior de ML II (L5), Signifyd (pela aquisição da Legiti, março de 2023)

Junho de 2022 – novembro de 2024 · San Jose, CA, EUA (remoto)

- Previsão de perdas: reduzi o tempo de experimentação do modelo em 93 % (de 16 horas para 1 hora), com a refatoração do código de simulação, multithreading e a troca de pandas por PySpark
- Reduzi em 77 % o tempo e o custo do cálculo de features em lote, do PostgreSQL para PySpark no Databricks
- Detecção de anomalias para análise de risco de fraude no Databricks (Unity Catalog, Delta Lake, MLflow, PySpark MLlib)

Engenheiro Líder de MLOps, Elemeno AI

Junho de 2021 – julho de 2022 · San Francisco, CA, EUA (remoto)

- Projetei e construí uma plataforma de MLOps inteiramente de código aberto para as Americanas (BVMF: AMER3): Kubeflow (KServe, Katib), MinIO, ArgoCD e GitLab CI no Google Kubernetes Engine, provisionados com Terraform e Helm; três repositórios abertos em github.com/elemeno-ai

Engenheiro de Software Sênior, Broad (Y Combinator, W21)

Novembro de 2020 – junho de 2021 · Londres, Reino Unido (remoto)

- Fonte única dos eventos bancários em Scala, ZIO, Event Sourcing e Kafka Streams

Engenheiro de Software, iU Pay / Guiabolso

Maio de 2019 – novembro de 2020 · São Paulo, Brasil (remoto)

- Contribuidor central do primeiro motor brasileiro de transferências instantâneas entre bancos, entregue oito meses antes do lançamento do Pix: motor de transações, compensação e modelo de dados no Apache Cassandra, com Apache Kafka e Event Sourcing

Desenvolvedor de Software, Stone (Nasdaq: STNE)

Outubro de 2017 – abril de 2019 · Rio de Janeiro, Brasil (remoto)

- Previsão de churn: migrei modelos de redes bayesianas para XGBoost/LightGBM no Apache Spark
- Reduzi em 35 % o custo logístico da troca de operadora móvel das maquininhas de cartão de crédito, com um sistema de recomendação baseado em qualidade de sinal e proximidade geográfica

Iniciação científica, LIOC – Laboratório de Instrumentação Oceanográfica, COPPE/UFRJ

Setembro de 2015 – outubro de 2017 · Rio de Janeiro, Brasil

- Construção de um glider submarino
- Construção e operação de um ROV (veículo submarino operado remotamente)
- Rastreamento por GPS, em tempo real, de barcos em competições: microcontrolador TI MSP430 com transmissão pela rede celular GSM (2G), e servidor em Python, PHP e MySQL
- Processamento de sinais em FPGA com LabVIEW (NI cRIO-9068) para um programa de comunicação submarina da Marinha do Brasil

Competências

- **Computação de alto desempenho**: C++/Kokkos, Fortran, OpenMP, MPI, CUDA, perfil com gprof, regtests do WW3, Nix
- **MLOps e engenharia de dados**: pipelines de ML de ponta a ponta, MLflow, Kubeflow, Amazon SageMaker, Apache Spark, PySpark, Databricks, Delta Lake, Apache Airflow, dbt, SQL
- **Nuvem e infraestrutura**: AWS (S3, EC2, EKS, EMR, Kinesis, Glue, DynamoDB, Redshift), Google Cloud (GKE), Kubernetes, Docker, Terraform, Helm, ArgoCD, CI/CD (GitHub Actions, GitLab CI)
- **Backend e IA**: Scala, Python, TypeScript, Apache Kafka, PostgreSQL, Apache Cassandra, RAG, MCP, DSPy, fine-tuning (QLoRA, DPO), Claude Code
- **Instrumentação**: microcontroladores (TI MSP430), FPGA (NI cRIO-9068, LabVIEW), GPS, GSM

Formação

Bacharelado em Engenharia Eletrônica e de Computação, Universidade Federal do Rio de Janeiro (UFRJ)

2013 – atual · Rio de Janeiro, Brasil

Projeto final em andamento: otimização do modelo de ondas WAVEWATCH III em GPU, com o LabECO/UFSC (github.com/h0ffmann/ww3-gpu). Temas principais: engenharia de software, big data e HPC.

Técnico em Eletrônica, Centro Federal de Educação Tecnológica CEFET/RJ

2010 – 2012 · Rio de Janeiro, Brasil

Eletrônica industrial e instrumentação.

Idiomas, certificações e prêmios

Português (nativo), inglês (C1, fluente), espanhol (leitura).

AWS Cloud Practitioner · AWS ML Specialty · AWS ML Engineer Associate · AWS Data Engineer Associate · PADI Rescue Diver

Oceanman Rio de Janeiro: 3º lugar na faixa de 30 a 39 anos, 10 km em águas abertas (setembro de 2025). Prêmio “Values VIP: Tenacious” da Signifyd por excelência técnica, por votação dos funcionários (fevereiro de 2024).

Outras obras com DOI: *marola-bench* (10.5281/zenodo.23352633); *picasso* (10.5281/zenodo.23311208); *Closed Source: The God that Failed* (10.5281/zenodo.23333656); *Nashkell: Rhizomatic experiments* (10.5281/zenodo.23356739).